

## Instrucciones práctica tema 8 – CLUSTERING

1-Implementar el algoritmo kmeans con los siguientes parámetros:

- Distancia: Euclidea/manhattan
- Numero de clusters
- Dataset

dataset: <https://shorturl.at/eqstC>

Como ejemplo utilizaremos de entradas un conjunto de datos en el que se analizan rasgos de la personalidad de usuarios de Twitter. 140 personalidades pertenecientes a diferentes áreas: deporte, cantantes, actores, etc.

Características de entrada:

usuario

“op” = Openness to experience – grado de apertura mental a nuevas experiencias

“co” =Conscientiousness – grado de orden, prolijidad, organización

“ex” = Extraversion – grado de timidez, solitario o participación ante el grupo social

“ag” = Agreeableness – grado de empatía con los demás, temperamento

“ne” = Neuroticism, – grado de neuroticismo, nervioso, irritabilidad, seguridad

Wordcount – Cantidad promedio de palabras usadas en sus tweets


Categoría – Actividad laboral del usuario (actor, cantante, etc.)

Utilizaremos el algoritmo K-means para que agrupe estos usuarios por sus similitudes en la personalidad. Si bien tenemos 8 columnas de entrada, sólo utilizaremos *op*, *ex* y *ag*

2- Realizar una pequeña experimentación que dadas las dos distancias, calcule y pinte en base a la puntuación de las medidas intra/intercluster (Davies-Bouldin Index )cuál es la mejor elección de clusters.


La similitud R para el grupo i con su grupo j más cercano se define como  $(S_i + S_j)/D_{ij}$ , donde  $S_i$  es la distancia promedio de cada punto en el grupo i a su centroide.  $D_{ij}$  es la distancia entre el centroide del grupo i y j

3- Mostrar el punto de codo, es decir donde la gráfica tiene un punto de inflexión .



4- Elegir a partir de ahora num. Cluster = 5.

Dibujar por pares en distintos colores los clústeres con sus centroides (*op/ex op/ag ex/ag*) o en una sola gráfica 3D (utiliza orto símbolo para los centroides)



5- Muestra los usuarios de cada cluster.

Rúbrica:

- 5- Puntos 1-2
- 6-7 Puntos 1-2-3
- 8 1-2-3-4-5 Análisis de los resultados
- 9-10- Utilización de otros atributos y medidas de calidad. Explicación de las formas de los clústeres en función de diferentes medidas.